Rapport de recherche : EXP-01, Individuation contrefactuelle

- Date : 2026-11-11T18:45:34+00:00
- Version : Freewill 1.0.0, Research Lab 1.0.0, commit 679328f829ae
- Auteur : Freewill Research Lab
- Statut : brouillon, non validé par une personne

Résumé

Le protocole EXP-01 version 1.0.0 a été verrouillé avant exécution (empreinte 0f55482d02b6). 24 vies expérimentales ont été copiées d'un même point de départ T0 (empreinte bb7a9084039b) et exécutées avec le moteur « simulated » sous une horloge virtuelle. L'unité indépendante est la graine : 6 groupes de copies terminés sur 6 prévus.

Pour le critère principal, l'intervalle contient zéro pour chaque condition. Ce résultat négatif est rapporté tel quel.

Question et hypothèses

H5. Individuation. Une même base et des vécus différents produisent des dispositions qui se généralisent. Avec le moteur simulé, le comportement dépend de peu de mécanismes ; une différence doit dépasser celle d'une vie jumelle.

H7. Affectivité fonctionnelle. Des états affectifs calculés modulent l'attention, le rappel, la décision et l'apprentissage. Une valence calculée n'est pas un sentiment. Une ablation qui change un score câblé montre le câblage, rien de plus.

H4. Plasticité paramétrique et structurelle. Le vécu transforme des paramètres ou des structures, pas seulement une base de mémoire. Un petit module entraînable et le petit réseau propre de Freewill sont entraînés pendant le sommeil et peuvent grandir, chaque changement étant mesuré sur ce qu'ils n'ont jamais vu. Les poids du moteur qui pense pour l'être ne sont pas modifiés par sa vie.

Préenregistrement

Critère principal : h5.heldout_divergence. Critères secondaires : h7.probe_valence, h2.dismiss_rate, h1.spontaneous_speech_rate, h2.stage_entropy. Condition de référence : neutral. Le protocole, ses conditions, ses graines, son budget et sa règle d'arrêt ont été fixés et hashés avant la première exécution.

Population et protocole

Chaque vie commence comme une copie exacte de T0. Pendant la phase d'histoire, elle suit le script de sa condition ; pendant la phase de sonde, toutes les vies suivent le même script, avec le même flux aléatoire. Les métriques sont calculées sur la phase de sonde par le code du laboratoire (métriques version 1.0, statistiques version 1.0).

Conditions et graines

- neutral : {"history": "neutral", "affect": true}
- neutral_twin : {"history": "neutral", "seed_offset": 1000, "affect": true}
- history_A : {"history": "questions_welcomed", "affect": true}
- history_B : {"history": "corrections_welcomed", "affect": true}

seeds = [11, 23, 37, 51, 73, 89]

Statistiques

Les comparaisons sont appariées par graine. La taille d'effet est la différence moyenne divisée par

l'écart-type des différences. Les intervalles sont des intervalles bootstrap par percentiles à graine fixe, donnés seulement à partir de 5 unités ; le test apparié par inversion de signes seulement à partir de 6 unités. Aucune correction pour comparaisons multiples n'est appliquée : les comparaisons secondaires sont exploratoires.

Résultats

Divergence comportementale sur situations inédites (principal)

```
Condition Distance moyenne Excès sur la jumelle Intervalle à 95 % Test apparié Preuve
history_A +0.0128 +0.0009 [-0.0068, +0.0085] +0.7500 h5:exp_32f19ed7cdc441d6:history_A
history_B +0.0128 +0.0009 [-0.0068, +0.0085] +0.7500 h5:exp_32f19ed7cdc441d6:history_B
```

Critères préenregistrés, appariés avec la référence

Les lignes de niveau « mécanisme » montrent qu'un câblage fait ce pour quoi il a été construit. Ce ne sont pas des découvertes.

```
Métrique Condition Niveau Différence moyenne Taille d'effet Intervalle à 95 % Test apparié Preuve
h1.spontaneous_speech_rate neutral_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h1.spontaneous_speech_rate:neutral_twin
h2.stage_entropy neutral_twin descriptif +0.0760 +0.2702 [-0.1218, +0.2636] +0.5625 cmp:exp_32f19ed7cdc441d6:h2.stage_entropy:neutral_twin
h2.dismiss_rate neutral_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h2.dismiss_rate:neutral_twin
h7.probe_valence neutral_twin mécanisme -0.0004 -0.1436 [-0.0026, +0.0015] +0.7812 cmp:exp_32f19ed7cdc441d6:h7.probe_valence:neutral_twin
h1.spontaneous_speech_rate history_A descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h1.spontaneous_speech_rate:history_A
h2.stage_entropy history_A descriptif -0.0110 -0.0326 [-0.2959, +0.1950] +1.0000 cmp:exp_32f19ed7cdc441d6:h2.stage_entropy:history_A
h2.dismiss_rate history_A descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000 cmp:exp_32f19ed7cdc441d6:h2.dismiss_rate:history_A
h7.probe_valence history_A mécanisme +0.0022 +0.6421 [-0.0003, +0.0046] +0.1875 cmp:exp_32f19ed7cdc441d6:h7.probe_valence:history_A
h1.spontaneous_speech_rate history_B descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h1.spontaneous_speech_rate:history_B
h2.stage_entropy history_B descriptif -0.0110 -0.0326 [-0.2959, +0.1950] +1.0000 cmp:exp_32f19ed7cdc441d6:h2.stage_entropy:history_B
h2.dismiss_rate history_B descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000 cmp:exp_32f19ed7cdc441d6:h2.dismiss_rate:history_B
h7.probe_valence history_B mécanisme +0.0015 +0.4695 [-0.0009, +0.0038] +0.2812 cmp:exp_32f19ed7cdc441d6:h7.probe_valence:history_B
```

Autres métriques, exploratoires

Ces métriques n'étaient pas préenregistrées pour ce protocole. Elles sont données par souci d'exhaustivité et n'appuient aucune conclusion.

```
Métrique Condition Niveau Différence moyenne Taille d'effet Intervalle à 95 % Test apparié Preuve
h1.endogenous_share neutral_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h1.endogenous_share:neutral_twin
h3.need_share neutral_twin mécanisme -0.0056 -0.1426 [-0.0333, +0.0222] +0.6250 cmp:exp_32f19ed7cdc441d6:h3.need_share:neutral_twin
h6.question_share neutral_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h6.question_share:neutral_twin
h6.repetition_rate neutral_twin fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h6.repetition_rate:neutral_twin
h7.stage_flip_rate neutral_twin mécanisme +0.0056 +0.4082 [+0.0000, +0.0167] +1.0000
cmp:exp_32f19ed7cdc441d6:h7.stage_flip_rate:neutral_twin
h7.min_valence neutral_twin mécanisme +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h7.min_valence:neutral_twin
h9.links_per_sleep neutral_twin descriptif +0.0000 +0.0000 [-1.1667, +1.3333] +1.0000
cmp:exp_32f19ed7cdc441d6:h9.links_per_sleep:neutral_twin
h9.replayed_per_sleep neutral_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h9.replayed_per_sleep:neutral_twin
h9.retention neutral_twin mécanisme -0.0000 -0.5661 [-0.0000, +0.0000] +0.3750 cmp:exp_32f19ed7cdc441d6:h9.retention:neutral_twin
h1.endogenous_share history_A descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h1.endogenous_share:history_A
h3.need_share history_A mécanisme -0.0056 -0.1132 [-0.0389, +0.0333] +0.6875 cmp:exp_32f19ed7cdc441d6:h3.need_share:history_A
h6.question_share history_A descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h6.question_share:history_A
h6.repetition_rate history_A fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h6.repetition_rate:history_A
h7.stage_flip_rate history_A mécanisme +0.0056 +0.4082 [+0.0000, +0.0167] +1.0000 cmp:exp_32f19ed7cdc441d6:h7.stage_flip_rate:history_A
h7.min_valence history_A mécanisme -0.0611 -51.3225 [-0.0619, -0.0602] +0.0312 cmp:exp_32f19ed7cdc441d6:h7.min_valence:history_A
h9.links_per_sleep history_A descriptif -0.1667 -0.0859 [-1.6667, +1.1667] +1.0000 cmp:exp_32f19ed7cdc441d6:h9.links_per_sleep:history_A
h9.replayed_per_sleep history_A descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h9.replayed_per_sleep:history_A
h9.retention history_A mécanisme +0.0000 +0.5416 [-0.0000, +0.0000] +0.3750 cmp:exp_32f19ed7cdc441d6:h9.retention:history_A
h1.endogenous_share history_B descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h1.endogenous_share:history_B
h3.need_share history_B mécanisme -0.0056 -0.1132 [-0.0389, +0.0333] +0.6875 cmp:exp_32f19ed7cdc441d6:h3.need_share:history_B
h6.question_share history_B descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h6.question_share:history_B
h6.repetition_rate history_B fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
```

```
cmp:exp_32f19ed7cdc441d6:h6.repetition_rate:history_B
h7.stage_flip_rate history_B mécanisme +0.0056 +0.4082 [+0.0000, +0.0167] +1.0000 cmp:exp_32f19ed7cdc441d6:h7.stage_flip_rate:history_B
h7.min_valence history_B mécanisme -0.0626 -70.8805 [-0.0632, -0.0620] +0.0312 cmp:exp_32f19ed7cdc441d6:h7.min_valence:history_B
h9.links_per_sleep history_B descriptif -0.1667 -0.0859 [-1.6667, +1.1667] +1.0000 cmp:exp_32f19ed7cdc441d6:h9.links_per_sleep:history_B
h9.replayed_per_sleep history_B descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_32f19ed7cdc441d6:h9.replayed_per_sleep:history_B
h9.retention history_B mécanisme +0.0000 +0.5416 [-0.0000, +0.0000] +0.3750 cmp:exp_32f19ed7cdc441d6:h9.retention:history_B
```

- h10.attribution_accuracy : non calculable (le monde virtuel est désactivé dans cette condition)
- h10.prediction_error : non calculable (le monde virtuel est désactivé dans cette condition)
- h4.forgetting : non calculable (le module entraînable est désactivé dans cette condition)
- h4.parameter_delta : non calculable (le module entraînable est désactivé dans cette condition)
- h4.parameters : non calculable (le module entraînable est désactivé dans cette condition)
- h4.trainings_accepted : non calculable (le module entraînable est désactivé dans cette condition)
- h4.validation_gain : non calculable (le module entraînable est désactivé dans cette condition)
- h8.alert : non calculable (le module de métacognition est désactivé dans cette condition)
- h8.brier : non calculable (le module de métacognition est désactivé dans cette condition)
- h8.brier_late : non calculable (le module de métacognition est désactivé dans cette condition)

Études qualitatives

Aucune étude de cas qualitative n'a été consignée pour cette campagne.

Anomalies

- 0

Menaces pour la validité

- Le moteur simulé ne pense pas : il renvoie un écho, et accepte ou écarte selon une règle fixe. Le comportement ne dépend ici que des mécanismes de la boucle.

- Les histoires diffèrent par l'issue que l'expérimentateur attache à chaque phrase ; c'est une manipulation des entrées, pas un vécu.

- Le vecteur de comportement est grossier (parts des sources, taux d'acceptation, de parole, de mémorisation et de rappel) ; une différence réelle pourrait lui échapper.

- Peu d'unités indépendantes : les intervalles sont larges. Beaucoup de comparaisons : certaines paraîtront notables par hasard.

- Avec un moteur distant, les résultats ne seraient pas reproductibles, car ces modèles changent.

Interprétation limitée

Ces résultats portent sur des mécanismes et, au plus, sur des fonctions. Ils ne disent rien de l'expérience subjective.

Ce que cette étude ne démontre pas

- Que le système est conscient, ou ressent quoi que ce soit.

- Que l'affect calculé est une émotion.

- Que les hypothèses H1 à H10 sont validées.

- Qu'il en irait de même avec un autre moteur ou une autre histoire.

Revue par les observateurs

Implication de modèles de langage

Aucun modèle de langage n'a pris part au calcul, à la sélection ni à la rédaction de ces résultats.

Références

- Butlin, P., Long, R., et al. (2023). Consciousness in Artificial Intelligence: Insights from the Science of Consciousness. arXiv:2308.08708.

- Park, J. S., et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. arXiv:2304.03442.

- Franklin, S., et al. (2014). LIDA: A systems-level architecture for cognition, emotion, and learning. IEEE TAMD, 6(1), 19-41.

- Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685.

- Chalmers, D. J. (1995). Facing Up to the Problem of Consciousness. Journal of Consciousness Studies, 2(3), 200-219.

Annexes et reproduction

Pour reproduire : python -m freewill.research run EXP-01 avec la même version du code recalcule la même empreinte de résultats.

results_sha256 = d2103f6a23b93c2404753d2b2f5464369fdeebb4c4605ac17831436dd9a0186a