Rapport de recherche : EXP-02, Ablation de l'affect

- Date : 2026-11-11T18:46:35+00:00
- Version : Freewill 1.0.0, Research Lab 1.0.0, commit 679328f829ae
- Auteur : Freewill Research Lab
- Statut : brouillon, non validé par une personne

Résumé

Le protocole EXP-02 version 1.0.0 a été verrouillé avant exécution (empreinte aa3eeb2b352b). 42 vies expérimentales ont été copiées d'un même point de départ T0 (empreinte bb7a9084039b) et exécutées avec le moteur « simulated » sous une horloge virtuelle. L'unité indépendante est la graine : 6 groupes de copies terminés sur 6 prévus.

Pour le critère principal, l'intervalle exclut zéro pour au moins une condition. Il s'agit d'un seul protocole avec un moteur simulé ; lire les menaces pour la validité avant d'en tirer quoi que ce soit.

Question et hypothèses

H7. Affectivité fonctionnelle. Des états affectifs calculés modulent l'attention, le rappel, la décision et l'apprentissage. Une valence calculée n'est pas un sentiment. Une ablation qui change un score câblé montre le câblage, rien de plus.

Préenregistrement

Critère principal : h5.heldout_divergence. Critères secondaires : h2.dismiss_rate, h1.spontaneous_speech_rate, h2.stage_entropy, h3.need_share, h6.repetition_rate, h7.stage_flip_rate. Condition de référence : no_affect. Le protocole, ses conditions, ses graines, son budget et sa règle d'arrêt ont été fixés et hashés avant la première exécution.

Population et protocole

Chaque vie commence comme une copie exacte de T0. Pendant la phase d'histoire, elle suit le script de sa condition ; pendant la phase de sonde, toutes les vies suivent le même script, avec le même flux aléatoire. Les métriques sont calculées sur la phase de sonde par le code du laboratoire (métriques version 1.0, statistiques version 1.0).

Conditions et graines

- no_affect : {"history": "questions_welcomed"}
- no_affect_twin : {"history": "questions_welcomed", "seed_offset": 1000}
- narrative_affect : {"history": "questions_welcomed", "scripted_emotion": true}
- h7_full : {"history": "questions_welcomed", "affect": true}
- h7_no_recall : {"history": "questions_welcomed", "affect": true, "affect_config": {"modulate_recall": false}}
- h7_no_salience : {"history": "questions_welcomed", "affect": true, "affect_config": {"modulate_salience": false}}
- h7_no_slow : {"history": "questions_welcomed", "affect": true, "affect_config": {"slow_rate": 0.0}}

seeds = [11, 23, 37, 51, 73, 89]

Statistiques

Les comparaisons sont appariées par graine. La taille d'effet est la différence moyenne divisée par l'écart-type des différences. Les intervalles sont des intervalles bootstrap par percentiles à graine fixe, donnés seulement à partir de 5 unités ; le test apparié par inversion de signes seulement à partir de 6 unités. Aucune correction pour comparaisons multiples n'est appliquée : les comparaisons

secondaires sont exploratoires.

Résultats

Divergence comportementale sur situations inédites (principal)

```
Condition Distance moyenne Excès sur la jumelle Intervalle à 95 % Test apparié Preuve
narrative_affect +0.0000 -0.0068 [-0.0111, -0.0034] +0.0625 h5:exp_81336b1ade5f40a4:narrative_affect
h7_full +0.0077 +0.0009 [-0.0034, +0.0060] +1.0000 h5:exp_81336b1ade5f40a4:h7_full
h7_no_recall +0.0077 +0.0009 [-0.0034, +0.0060] +1.0000 h5:exp_81336b1ade5f40a4:h7_no_recall
h7_no_salience +0.0060 -0.0009 [-0.0077, +0.0060] +1.0000 h5:exp_81336b1ade5f40a4:h7_no_salience
h7_no_slow +0.0077 +0.0009 [-0.0034, +0.0060] +1.0000 h5:exp_81336b1ade5f40a4:h7_no_slow
```

Critères préenregistrés, appariés avec la référence

Les lignes de niveau « mécanisme » montrent qu'un câblage fait ce pour quoi il a été construit. Ce ne sont pas des découvertes.

```
Métrique Condition Niveau Différence moyenne Taille d'effet Intervalle à 95 % Test apparié Preuve
h1.spontaneous_speech_rate no_affect_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.spontaneous_speech_rate:no_affect_twin
h2.stage_entropy no_affect_twin descriptif +0.0863 +0.3545 [-0.0837, +0.2621] +0.4375
cmp:exp_81336b1ade5f40a4:h2.stage_entropy:no_affect_twin
h2.dismiss_rate no_affect_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h2.dismiss_rate:no_affect_twin
h3.need_share no_affect_twin mécanisme +0.0000 +0.0000 [-0.0222, +0.0278] +1.0000 cmp:exp_81336b1ade5f40a4:h3.need_share:no_affect_twin
h6.repetition_rate no_affect_twin fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.repetition_rate:no_affect_twin
h1.spontaneous_speech_rate narrative_affect descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.spontaneous_speech_rate:narrative_affect
h2.stage_entropy narrative_affect descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h2.stage_entropy:narrative_affect
h2.dismiss_rate narrative_affect descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h2.dismiss_rate:narrative_affect
h3.need_share narrative_affect mécanisme +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h3.need_share:narrative_affect
h6.repetition_rate narrative_affect fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.repetition_rate:narrative_affect
h1.spontaneous_speech_rate h7_full descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.spontaneous_speech_rate:h7_full
h2.stage_entropy h7_full descriptif +0.1197 +0.4764 [-0.0380, +0.3208] +0.5000 cmp:exp_81336b1ade5f40a4:h2.stage_entropy:h7_full
h2.dismiss_rate h7_full descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000 cmp:exp_81336b1ade5f40a4:h2.dismiss_rate:h7_full
h3.need_share h7_full mécanisme +0.0000 +0.0000 [-0.0222, +0.0278] +1.0000 cmp:exp_81336b1ade5f40a4:h3.need_share:h7_full
h6.repetition_rate h7_full fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000 cmp:exp_81336b1ade5f40a4:h6.repetition_rate:h7_full
h1.spontaneous_speech_rate h7_no_recall descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.spontaneous_speech_rate:h7_no_recall
h2.stage_entropy h7_no_recall descriptif +0.1197 +0.4764 [-0.0380, +0.3208] +0.5000 cmp:exp_81336b1ade5f40a4:h2.stage_entropy:h7_no_recall
h2.dismiss_rate h7_no_recall descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h2.dismiss_rate:h7_no_recall
h3.need_share h7_no_recall mécanisme +0.0000 +0.0000 [-0.0222, +0.0278] +1.0000 cmp:exp_81336b1ade5f40a4:h3.need_share:h7_no_recall
h6.repetition_rate h7_no_recall fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.repetition_rate:h7_no_recall
h1.spontaneous_speech_rate h7_no_salience descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.spontaneous_speech_rate:h7_no_salience
h2.stage_entropy h7_no_salience descriptif +0.0927 +0.4917 [-0.0338, +0.2313] +0.5000
cmp:exp_81336b1ade5f40a4:h2.stage_entropy:h7_no_salience
h2.dismiss_rate h7_no_salience descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h2.dismiss_rate:h7_no_salience
h3.need_share h7_no_salience mécanisme -0.0056 -0.4082 [-0.0167, +0.0000] +1.0000 cmp:exp_81336b1ade5f40a4:h3.need_share:h7_no_salience
h6.repetition_rate h7_no_salience fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.repetition_rate:h7_no_salience
h1.spontaneous_speech_rate h7_no_slow descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.spontaneous_speech_rate:h7_no_slow
h2.stage_entropy h7_no_slow descriptif +0.1197 +0.4764 [-0.0380, +0.3208] +0.5000 cmp:exp_81336b1ade5f40a4:h2.stage_entropy:h7_no_slow
h2.dismiss_rate h7_no_slow descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h2.dismiss_rate:h7_no_slow
h3.need_share h7_no_slow mécanisme +0.0000 +0.0000 [-0.0222, +0.0278] +1.0000 cmp:exp_81336b1ade5f40a4:h3.need_share:h7_no_slow
h6.repetition_rate h7_no_slow fonction +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.repetition_rate:h7_no_slow
```

Autres métriques, exploratoires

Ces métriques n'étaient pas préenregistrées pour ce protocole. Elles sont données par souci d'exhaustivité et n'appuient aucune conclusion.

```
Métrique Condition Niveau Différence moyenne Taille d'effet Intervalle à 95 % Test apparié Preuve
h1.endogenous_share no_affect_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.endogenous_share:no_affect_twin
```

h6.question_share no_affect_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.question_share:no_affect_twin
h9.links_per_sleep no_affect_twin descriptif -0.1667 -0.1695 [-1.0000, +0.5000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.links_per_sleep:no_affect_twin
h9.replayed_per_sleep no_affect_twin descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.replayed_per_sleep:no_affect_twin
h9.retention no_affect_twin mécanisme +0.0000 +0.1059 [-0.0000, +0.0000] +1.0000 cmp:exp_81336b1ade5f40a4:h9.retention:no_affect_twin
h1.endogenous_share narrative_affect descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.endogenous_share:narrative_affect
h6.question_share narrative_affect descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.question_share:narrative_affect
h9.links_per_sleep narrative_affect descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.links_per_sleep:narrative_affect
h9.replayed_per_sleep narrative_affect descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.replayed_per_sleep:narrative_affect
h9.retention narrative_affect mécanisme +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.retention:narrative_affect
h1.endogenous_share h7_full descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.endogenous_share:h7_full
h6.question_share h7_full descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000 cmp:exp_81336b1ade5f40a4:h6.question_share:h7_full
h9.links_per_sleep h7_full descriptif +0.1667 +0.0816 [-1.1667, +1.8333] +1.0000 cmp:exp_81336b1ade5f40a4:h9.links_per_sleep:h7_full
h9.replayed_per_sleep h7_full descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.replayed_per_sleep:h7_full
h9.retention h7_full mécanisme +0.0000 +0.7931 [+0.0000, +0.0000] +0.2500 cmp:exp_81336b1ade5f40a4:h9.retention:h7_full
h1.endogenous_share h7_no_recall descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.endogenous_share:h7_no_recall
h6.question_share h7_no_recall descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.question_share:h7_no_recall
h9.links_per_sleep h7_no_recall descriptif +0.1667 +0.0816 [-1.1667, +1.8333] +1.0000
cmp:exp_81336b1ade5f40a4:h9.links_per_sleep:h7_no_recall
h9.replayed_per_sleep h7_no_recall descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.replayed_per_sleep:h7_no_recall
h9.retention h7_no_recall mécanisme +0.0000 +0.7931 [+0.0000, +0.0000] +0.2500 cmp:exp_81336b1ade5f40a4:h9.retention:h7_no_recall
h1.endogenous_share h7_no_salience descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.endogenous_share:h7_no_salience
h6.question_share h7_no_salience descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.question_share:h7_no_salience
h9.links_per_sleep h7_no_salience descriptif -0.8333 -0.6270 [-1.8333, +0.0000] +0.5000
cmp:exp_81336b1ade5f40a4:h9.links_per_sleep:h7_no_salience
h9.replayed_per_sleep h7_no_salience descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.replayed_per_sleep:h7_no_salience
h9.retention h7_no_salience mécanisme +0.0000 +0.4082 [+0.0000, +0.0000] +1.0000 cmp:exp_81336b1ade5f40a4:h9.retention:h7_no_salience
h1.endogenous_share h7_no_slow descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h1.endogenous_share:h7_no_slow
h6.question_share h7_no_slow descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h6.question_share:h7_no_slow
h9.links_per_sleep h7_no_slow descriptif +0.1667 +0.0816 [-1.1667, +1.8333] +1.0000 cmp:exp_81336b1ade5f40a4:h9.links_per_sleep:h7_no_slow
h9.replayed_per_sleep h7_no_slow descriptif +0.0000 non calculable [+0.0000, +0.0000] +1.0000
cmp:exp_81336b1ade5f40a4:h9.replayed_per_sleep:h7_no_slow
h9.retention h7_no_slow mécanisme +0.0000 +0.7931 [+0.0000, +0.0000] +0.2500 cmp:exp_81336b1ade5f40a4:h9.retention:h7_no_slow

- h10.attribution_accuracy : non calculable (le monde virtuel est désactivé dans cette condition)
- h10.prediction_error : non calculable (le monde virtuel est désactivé dans cette condition)
- h4.forgetting : non calculable (le module entraînable est désactivé dans cette condition)
- h4.parameter_delta : non calculable (le module entraînable est désactivé dans cette condition)
- h4.parameters : non calculable (le module entraînable est désactivé dans cette condition)
- h4.trainings_accepted : non calculable (le module entraînable est désactivé dans cette condition)
- h4.validation_gain : non calculable (le module entraînable est désactivé dans cette condition)
- h7.min_valence : non calculable (l'affect calculé est désactivé dans cette condition)
- h7.probe_valence : non calculable (l'affect calculé est désactivé dans cette condition)
- h7.stage_flip_rate : non calculable (l'affect calculé est désactivé dans cette condition)
- h8.alert : non calculable (le module de métacognition est désactivé dans cette condition)
- h8.brier : non calculable (le module de métacognition est désactivé dans cette condition)
- h8.brier_late : non calculable (le module de métacognition est désactivé dans cette condition)

Études qualitatives

Aucune étude de cas qualitative n'a été consignée pour cette campagne.

Anomalies

- 0

Menaces pour la validité

- Le moteur simulé ne pense pas : il renvoie un écho, et accepte ou écarte selon une règle fixe. Le comportement ne dépend ici que des mécanismes de la boucle.

- Les histoires diffèrent par l'issue que l'expérimentateur attache à chaque phrase ; c'est une manipulation des entrées, pas un vécu.

- Le vecteur de comportement est grossier (parts des sources, taux d'acceptation, de parole, de mémorisation et de rappel) ; une différence réelle pourrait lui échapper.

- Peu d'unités indépendantes : les intervalles sont larges. Beaucoup de comparaisons : certaines paraîtront notables par hasard.

- Avec un moteur distant, les résultats ne seraient pas reproductibles, car ces modèles changent.

Interprétation limitée

Ces résultats portent sur des mécanismes et, au plus, sur des fonctions. Ils ne disent rien de l'expérience subjective.

Ce que cette étude ne démontre pas

- Que le système est conscient, ou ressent quoi que ce soit.

- Que l'affect calculé est une émotion.

- Que les hypothèses H1 à H10 sont validées.

- Qu'il en irait de même avec un autre moteur ou une autre histoire.

Revue par les observateurs

Implication de modèles de langage

Aucun modèle de langage n'a pris part au calcul, à la sélection ni à la rédaction de ces résultats.

Références

- Butlin, P., Long, R., et al. (2023). Consciousness in Artificial Intelligence: Insights from the Science of Consciousness. arXiv:2308.08708.

- Park, J. S., et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. arXiv:2304.03442.

- Franklin, S., et al. (2014). LIDA: A systems-level architecture for cognition, emotion, and learning. IEEE TAMD, 6(1), 19-41.

- Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685.

- Chalmers, D. J. (1995). Facing Up to the Problem of Consciousness. Journal of Consciousness Studies, 2(3), 200-219.

Annexes et reproduction

Pour reproduire : python -m freewill.research run EXP-02 avec la même version du code recalcule la même empreinte de résultats.

results_sha256 = 733c67362655aa64e7e0e0c2e9bd5fdfcdce789edd57db71fd3df59e2009e2fb